

Asistente Documental Inteligente (RAG)

Sistema de Generación Aumentada por Recuperación (RAG) completamente funcional y local. Permite interactuar con documentos PDF privados utilizando Modelos de Lenguaje de Gran Escala (LLMs) de código abierto, garantizando respuestas precisas y libres de alucinaciones.


Repositorio: [<https://github.com/pitsburg8280-cmyk/asistente-documental-rag>]

Características Principales

Característica Descripción
----- -----
100% Local Sin dependencias de APIs comerciales ni compromiso de privacidad
Procesamiento de PDFs Extracción robusta de texto con manejo de metadatos
Embeddings Semánticos Codificación vectorial con `all-MiniLM-L6-v2`
Base de Datos Vectorial ChromaDB persistente en disco para búsqueda de alta velocidad
Mitigación de Alucinaciones Prompts estrictos que restringen respuestas al contexto documental
Interfaz Profesional UI interactiva con Streamlit y manejo de historial
Rendimiento Optimizado Compatible con hardware de gama media (GPU opcional)
OCR Integrado Procesamiento de PDFs escaneados e imágenes con Tesseract

Arquitectura del Sistema

Flujo de Datos



Instalación y Configuración

Requisitos Previos

- Python 3.9+
- [Ollama](https://ollama.com) instalado localmente
- [Tesseract OCR](https://github.com/UB-Mannheim/tesseract/wiki) (para PDFs escaneados)
- Git

1. Clonar el Repositorio

```
``bash  
git clone https://github.com/pitsburg8280-cmyk/asistente-documental-rag.git  
cd asistente-documental-rag
```

2. Crear Entorno Virtual

```
python -m venv venv
```

Windows

```
venv\Scripts\activate
```

macOS/Linux

```
source venv/bin/activate
```

3. Instalar Dependencias

```
pip install -r requirements.txt
```

4. Descargar Modelo LLM

```
ollama pull llama3.2:3b
```

5. Ejecutar la Aplicación

```
streamlit run main.py
```

La aplicación estará disponible en <http://localhost:8501>

Guía de Uso

Opción 1: Carga Directa desde el Navegador (Recomendada)

1. Abre la aplicación con `streamlit run main.py`
2. Arrastra o selecciona tus PDFs en el panel lateral (sección "Cargar Documentos")
3. Haz clic en "Procesar Documentos Subidos"
4. Espera a que el sistema indexe los documentos
5. Comienza a hacer preguntas en la interfaz de chat

Opción 2: Carpeta Local (Avanzada)

1. Coloca tus PDFs en la carpeta `data/` (opcional)
2. Inicia la aplicación con `streamlit run main.py`
3. Haz clic en "Procesar Documentos Locales" en el panel lateral
4. Realiza consultas en la interfaz de chat

Gestión de Documentos

Visualizar: Lista de PDFs cargados en el panel lateral

Eliminar: Botón  junto a cada archivo para removerlo

Limpiar DB: Botón "Limpiar Base de Datos" para reiniciar el sistema

Configuración Avanzada

Edita `config.py` para personalizar:

`CHUNK_SIZE` : Tamaño de fragmentos (default: 500)

`CHUNK_OVERLAP` : Solapamiento entre chunks (default: 100)

`TOP_K` : Documentos a recuperar (default: 10)

`MODEL_NAME` : Modelo de Ollama (default: llama3.2:3b)

Pruebas de Estrés

Ejecuta las pruebas de robustez:


```
python tests/test_stress.py
```

Mitigación de Alucinaciones

El sistema implementa múltiples capas de seguridad:

1. Prompt del Sistema Estricto: "Responde ÚNICAMENTE basándote en el contexto proporcionado..."
2. Instrucción de Negación: "Si la respuesta no está en el contexto, responde: 'No tengo información...'"
3. Verificación de Contexto: El retriever debe encontrar documentos relevantes con similitud $>$ umbral

Estructura de Sesiones



Licencia

Este proyecto es de uso académico y educativo.